

[소프트웨어학과]

# 영상인식을 위한 딥러닝 아키텍처 초기연구

(Basic research on deep learning network architecture for visual recognition)

[중간보고서]

Version 1.0

2023.07.30.

학번: 201920811

이름: 이동현

지도교수: 유종빈

## 목 차

요약 .....	3
1. 개요 .....	3
2. 선행 연구 조사 .....	4
3. 프로젝트 진행.....	8
3-1. 멘토멘티 프로젝트.....	8
3-2. 산학협력 프로젝트 (결함예측).....	9
3-3. 개인 프로젝트 (Continual Learning) .....	9
4. 결론 .....	9

## 요약

본 연구의 목적은 영상인식 딥러닝의 독자연구에 앞서 기존의 지식들을 학습하고 연구를 수행할 수 있도록 준비하는 것이다. 이를 위해 기존의 딥러닝 논문들을 정독하고 요약본을 작성하고 있다. 또한 세 가지 프로젝트를 진행하고 있는데, 연구실에서 진행 중인 멘토멘티 주차별 프로젝트, 산학협력 결함예측 프로젝트, 그리고 개인적으로 진행 중인 Continual Learning 프로젝트이다. 기존의 연구 자료들을 읽고 이해한 뒤 직접 프로젝트들을 통해 구현하고 실습해 봄으로써 새로운 연구를 진행하고 논문을 작성할 수 있는 연구자가 되기 위한 시작점까지 정진해 나가고 있다.

## 1. 개요

본 연구의 목적은 최신 Vision transformer 와 Convolutional neural networks 기반의 아키텍처에 대한 이해와 실습을 통해 연구를 수행할 수 있는 준비를 하는 것이다. 선행 연구를 조사하고 이해하여 직접 구현하는 과정을 통한 딥러닝 아키텍처의 높은 이해를 달성하는 것이 목표이다. 따라서 CNN 의 좋은 선행 연구들을 논문의 형태로 읽고 학습한 뒤 Review 해 보았고, 나만의 양식으로 요약본을 작성해 보았다. 또한 배운 지식을 직접 코드로 작성하고 적용해볼 수 있도록 프로젝트들을 진행하고 있다.

이번 연구는 연구실 내에서 자체 진행중인 멘토멘티 프로젝트와 학과에서 진행중인 산학협력 프로젝트와 연계하여 진행하고 있다. 또한 지도교수 유종빈 교수님과 매주 대면 면담을 통해 연구 내용 및 진행도를 점검하며 진행하고 있다.

중간보고서 작성 이전까지의 기간(2023.07.03 – 2023.07.30) 내의 활동 내용, 논문 Review, 프로젝트별 코드, 보고서 및 발표자료가 포함된 모든 주차 별 연구일지들은 GitHub Repository<sup>1</sup>에서 확인할 수 있다.

---

<sup>1</sup> <https://github.com/Chihiro0623/2023summer-selfstudy1>

## 2. 선행 연구 조사

기존 논문을 읽고 이해하는 것은 해당 분야에 대한 새로운 지식을 받아들임과 동시에 이미 연구된 내용을 되풀이하는 실수를 줄이는 데 의의가 있다. 연구실 멘토멘티 프로그램에서는 주차별로 주제 (표 1)를 정해 논문을 읽고 읽으면서 알게 된 점과 자신의 생각을 짧게 정리하여 발표하는 활동을 진행하고 있다. 발표하고 질의하는 과정에서 혼자서는 생각하지 못했던 것도 알게 되고 궁금했던 점도 해소할 수 있었다.

주차	주제
1-2	Classification
3	Knowledge distillation
4-5	Deep learning engineering
6	Detection & Segmentation
7-8	Network analysis

표 1. 멘토멘티 프로그램 주차별 주제.

주차	논문 제목	학회	연도
1	ImageNet Classification with Deep Convolutional Neural Networks	NIPs	2017
	Very Deep Convolutional Networks for Large-Scale Image Recognition	Arxiv	2014
	Deep Residual Learning for Image Recognition	CVPR	2016
	CutMix: Regularization Strategy to Train Strong Classifiers with Localizable Features	ICCV	2019
2	Squeeze-and-Excitation Networks	CVPR	2018
	CBAM: Convolutional Block Attention Module	ECCV	2018
	EfficientNet: Rethinking Model Scaling for Convolutional Neural Networks	ICML	2019
	Distilling the Knowledge in a Neural Network	NIPs	2014
3	mixup: Beyond Empirical Risk Minimization	ICLR	2018
	Batch Normalization: Accelerating Deep Network Training by Reducing Internal Covariate Shift	ICML	2015
	RandAugment: Practical automated data augmentation with a reduced search space	CVPR	2020
4	ResNet strikes back: An improved training procedure in timm	Arxiv	2021
	AutoAugment: Learning Augmentation Policies from Data	CVPR	2019
	Random Erasing Data Augmentation	AAAI	2020

표 2. 연구 기간(2023.07.03 – 2023.07.30)동안 읽은 논문 목록.

연구 기간(2023.07.03 – 2023.07.30)동안 Review 한 논문의 목록은 표 2 와 같다. 논문을 정독하며 Google Sheet 를 사용해 자체 양식으로 정리하였다 (그림 1). 자체 양식에서는 원 논문의 목차를 큰 틀로 잡으면서 핵심 문장들을 최대한 변형하지 않고 발췌하는 형식으로 정리하여 이후 다시 읽어보았을 때 논문을 읽었던 과정이 다시 머릿속으로 쉽게 되풀이될 수 있도록 하였다.

ImageNet Classification with Deep Convolutional Neural Networks 와 mixup: Beyond Empirical Risk Minimization 의 두 논문에 대해서는 발표 자료 (그림 2)를 만들어 활용하였다. 5 분 내외라는 발표 시간에 맞추기 위해 최대한 요점만을 간결하게 정리하여 설명하였고, 발표 이후에는 Q&A 를 진행하였다. Q&A 과정을 통해 논문의 내용을 잘 이해했는지를 점검해볼 수 있었을 뿐만

아니라 해당 논문의 내용이 아직까지도 유효한지, 추가적인 학습을 진행하였는지를 확인할 수 있었고, 혼자서는 미처 생각하지 못했던 내용이나 논문 내용과 관련된 다른 연구 내용 또한 들을 수 있었다.

### ImageNet Classification with Deep Convolutional Neural Networks

#### Abstract

##### model

60 million parameters

650,000 neurons

five convolutional layers, some of which are followed by max-pooling layers, and three fully-connected layers with a final 1000-way softmax.

##### faster training

non-saturating neurons

a very efficient GPU implementation of the convolution operation

##### reduce overfitting in fully-connected layers

dropout

#### Discussion

depth really is important

#### Introduction

기존 개선법

collect larger datasets,

learn more powerful models

use better techniques for preventing overfitting.

Until recently, datasets of labeled images were relatively small

그림 1. ImageNet Classification with Deep Convolutional Neural Networks 논문 Review 의 일부. 논문을 정독하며 논문의 목차에 따라 핵심 단어와 문장 위주로 정리하였음.

## Architecture

- 5 Convs + 3 FC to 1000 classes

- 특이점들

- ReLU Nonlinearity
- Multiple GPUs
- Local Response Normalization
- Overlapping Pooling




그림 2. ImageNet Classification with Deep Convolutional Neural Networks 논문의 발표 자료의 일부. 5 분 내외라는 발표 시간에 맞추기 위해 최대한 요점만을 간결히 정리하는 것을 목표로 하였음.

이어서 각 논문들의 내용을 정리해 보았다. **ImageNet Classification with Deep Convolutional Neural Networks** 는 GPU 가 발전하고, Label 된 학습 데이터가 많아져 CNN 에게 유리한 상황이 왔을 때 쓰여진 논문으로, 이전의 개선법들이었던 collect larger datasets, learn more powerful models, use better techniques for preventing overfitting 에서 벗어나 모델의 깊이의 중요성을 확인하고, 기존의 Standard Feedforward Neural Networks 들이 아닌 CNN 의 가능성을 보여준 논문이다.

**Very Deep Convolutional Networks for Large-Scale Image Recognition** 은 3x3 Convolution Filter 를 세 번 사용하는 방식으로 Layer 를 더 깊게 쌓은 모델인 VGGNet 을 제시한 논문이다.

3x3 Filter 를 세 번 사용하는 것은 7x7 크기의 Filter 를 한 번 쓰는 것과 같은 크기의 Receptive Field 를 가지지만, 그럼에도 논문에서 3x3 Filter 를 사용한 이유는 Non-Linearity 가 증가하고 Parameter 의 수를 감소시킬 수 있기 때문이다. 또한 3x3 은 상하좌우의 개념을 표현할 수 있는 가장 작은 크기이기도 하다. 이 논문은 Filter 를 조절하여 더 깊은 모델을 만들면 성능이 더 향상될 수 있다는 것을 보여주었다.

**Deep Residual Learning for Image Recognition** 은 ReLU 와 Residual Learning 이라는 기법을 이용하여 더 깊은 Layer 의 ResNet 모델을 제시한 논문이다. Residual Learning 은 목표 출력이 아니라 출력과 입력의 차이를 학습시키는 방식으로, 작은 차이를 학습시키는 것이 아예 새로운 결과를 학습시키는 것보다 훨씬 쉽다는 점을 이용해 학습시킨다. 이를 위해 Shortcut 을 이용한 Identity Mapping 방식을 활용하였다. 또한 VGGNet 이후 더 깊은 모델을 만들기 위해서는 vanishing/exploding gradients problem 을 먼저 해결해야 했다. 이를 위해 논문에서는 ReLU 라는 Activation 을 활용한다. 이러한 기법들을 활용하여 만들어진 ResNet 은 이후 대부분의 연구에서 Baseline 또는 기초 모델로서 활용되게 된다.

**CutMix: Regularization Strategy to Train Strong Classifiers with Localizable Features** 는 Train Data 의 일부분을 잘라 붙이는 방식의 CutMix 라는 Data Augmentation 기법을 제시한 논문이다. CutMix 는 적은 연산량을 요구하면서도 높은 성능 향상을 보인다. CutMix 는 학습 데이터를 변형시켜 모델의 Generalization 능력을 향상시키고 Dropout 과 유사한 방식을 통해 Regularization 을 유도할 수 있다. 또한 적대적 입력이나 학습 데이터의 분포에서 벗어난 데이터들에 대한 Model Robustness 도 향상시킬 수 있다.

**Squeeze-and-Excitation Networks** 은 "Squeeze-and-Excitation" Block 이라는 모델의 구성요소를 제시하여 Channel-wise Training 의 중요성을 알려준 논문이다. Squeeze-and-Excitation Networks 도 적은 연산량을 요구하면서도 높은 성능 향상을 보인다. 모델의 Channel 들은 학습을 거듭하면서 앞 Layer 는 Class 들 간 비슷한 Activation 분포를 보이면서도 뒤 Layer 로 갈수록 Class 들 간에 다른 선호를 띤 분포를 띄게 된다. 이 논문에서는 이러한 Channel 들을 Squeeze 하고 다시 Excitation 하는 방식을 통해 분포를 Recalibration 시켜 모델의 성능을 향상시켰다.

**CBAM: Convolutional Block Attention Module** 은 Attention 기법을 이용하여 위 논문의 "Squeeze-and-Excitation"처럼 학습 과정에서 Channel 뿐만 아니라 Spatial 의 차원에서도 Recalibration 을 수행할 수 있는 CBAM 모듈을 제시한 논문이다. 이 논문에서는 두 가지의 Pooling 방식을 활용한 Channel Attention Module 과 Spatial Attention Module 을 차례대로 배치하고 이를 다시 원본 데이터와 합침으로서 Residual Learning 과 유사하게 모델에 어떤 feature 에 집중하여 학습하는 것이 좋을지 알려주는 방식을 제시한다.

**EfficientNet: Rethinking Model Scaling for Convolutional Neural Networks** 는 모델의 크기를 키울 때, Depth, Width, Resolution 세 차원을 같은 비율로 유지하면서 성장시키는 것이 중요하다는 것을 밝혀낸 논문이다. 해당 논문에서는 grid search 를 통해 작은 모델에서의 비율을 알아내어 그 비율의 제곱수대로 Depth, Width, Resolution 을 늘리는 방식을 제시하였다.

**Distilling the Knowledge in a Neural Network** 은 전문가 모델들을 통한 Ensemble 과 Soft Label 을 소개한 논문이다. 먼저 학습 시, Teacher Model 은 Student Model 에게 기존의 1 과 0 으로 이루어진 Hard Label 이 아닌 Teacher Model 의 예측 결과를 토대로 연산한 Soft

Label 으로 Student Model 을 학습시키게 된다. 이후 test 시에는 Gating Network 는 데이터를 입력 받으면 각 전문가 모델들 중 어떤 모델에 해당 데이터를 맡길지 판단하고, 해당 전문가 모델과 Generalist 모델의 결과를 참고하여 최종 결과를 출력하게 된다.

**mixup: Beyond Empirical Risk Minimization** 은 두 개의 테스트 데이터를 섞는 mixup 이라는 data augmentation 을 제시한 논문이다. mixup 기법을 사용하면 큰 모델이 작은 데이터의 모든 분포를 외워버려 Generalization 능력이 떨어지는 overfit 을 방지할 수 있고, 모델의 Regularization 과 Robustness 를 향상시킬 수 있다. 따라서 mixup 을 통해 학습한 모델은 데이터들의 상관관계 또한 학습하게 되어 0 과 1 의 이진적 방식이 아닌 선형적으로 작동하게 되고, 이러한 결과는 decision boundary graph 에서 완화된 decision boundary 를 통해 확인할 수 있다.

**Batch Normalization: Accelerating Deep Network Training by Reducing Internal Covariate Shift** 는 deep network 의 학습 속도를 저해시키는 internal covariate shift 를 해결하기 위한 방안으로 Batch Normalization 을 제시한 논문이다. Batch Normalization 은 Mini batch 의 평균과 표준분포 통계 데이터를 활용하여 Input Data 에 학습된 값을 곱하고 더함으로써 Covariate Shift 를 해결하였다. Batch Normalization 을 활용하면 큰 Learning Rate 를 사용할 수 있고, 모델의 성능이 initialization 에 종속되는 점을 완화시킬 수 있고, regularization 능력을 향상시킬 수 있다.

**RandAugment: Practical automated data augmentation with a reduced search space** 는 여러 가지 data augmentation 들을 최소화된 parameter 를 통해 적은 search space 로도 좋은 성능을 낼 수 있는 RandAugment 를 제시한 논문이다. 이를 통해 각 Data Augmentation 에 대한 전문적 지식 없이도 학습에 적합한 Data Augmentation 방식을 찾아낼 수 있다.

**ResNet strikes back: An improved training procedure in timm** 은 모델을 학습시키는 방법에 따라 성능이 많이 변할 수 있고 체계적인 학습을 위해서는 timm 이라는 library 를 잘 사용하는 것이 중요하다는 것을 알려준 논문이다. 이 논문은 ResNet 을 바탕으로 최적의 학습 방식을 찾기 위한 상세한 과정을 담고 있으며, 기존의 다른 논문들이 성능 비교를 위해 보고한 Accuracy 가 학습 방식에 따라 달라질 수 있다는 것을 알려준 논문이다.

**AutoAugment: Learning Augmentation Policies from Data** 는 데이터들을 RNN 을 활용하여 데이터 증강 방식이 적합할지 미리 파악하고 적용시키는 AutoAugment 를 제시한 논문이다. AutoAugment 는 기존의 수많은 Data augmentation 들을 2 개씩 묶어 search space 를 구성하여 탐색한다. AutoAugment 를 활용하면 데이터에 최적화된 Augmentation 을 자동으로 쉽게 수행할 수 있다.

**Random Erasing Data Augmentation** 는 학습 데이터의 일부를 지우는 Random Erasing 이라는 Data Augmentation 을 제안한 논문이다. 학습 데이터의 일부를 지우면 모델의 Generalization 능력을 개선시킬 수 있고, 지운 영역에 어떤 값을 넣느냐에 따라 성능이 달라질 수 있다. Random Erasing 은 기존의 모델을 거의 변화시키지 않으면서 무시할 수 있을 만큼의 적은 연산으로도 도입이 가능하며, 다른 Data Augmentation 에 추가적으로 활용할 수 있다.

이후 남은 연구 기간(2023.07.31 – 2023.08.27)동안 Review 할 논문의 목록은 표 3 과 같다. 이후 논문들에게도 이전과 같은 방식으로 자체 양식의 요약물을 만들고 발표를 진행할 예정이다.

주차	논문 제목	학회	연도
5&6	Rich feature hierarchies for accurate object detection and semantic segmentation	CVPR	2014
	Faster R-CNN: Towards Real-Time Object Detection with Region Proposal Networks	NIPs	2015
	You Only Look Once: Unified, Real-Time Object Detection	CVPR	2016
	SSD: Single Shot MultiBox Detector	ECCV	2016
	Feature Pyramid Networks for Object Detection	CVPR	2017
7	An Image is Worth 16x16 Words: Transformers for Image Recognition at Scale	ICLR	2021
	Methods for interpreting and understanding deep neural networks	DSP	2018
	Grad-CAM: Visual Explanations from Deep Networks via Gradient-based Localization	ICCV	2017
8	Intriguing Properties of Vision Transformers	NIPs	2021
	ImageNet-trained CNNs are biased towards texture; increasing shape bias improves accuracy and robustness	ICLR	2019
	How Do Vision Transformers Work?	ICLR	2022

표 3. 남은 연구 기간(2023.07.31 – 2023.08.27)동안 읽을 예정인 논문 목록.

### 3. 프로젝트 진행

연구 기간동안 크게 3 개의 프로젝트를 진행하고 있다. 프로젝트에서 pytorch 를 이용해 직접 코드를 작성하고 결과를 확인하면서 논문에서 배운 지식을 직접 실현해볼 수 있었고 Python 구현 능력도 향상시킬 수 있었다. 이러한 구현 능력은 이후 새로운 지식을 향한 연구를 하기 위해 갖춰야 할 필수적인 능력이다.

#### 3-1. 멘토멘티 프로젝트

멘토멘티 프로젝트에서는 매주 과제를 내고 해결하는 것을 목표로 하고 있다. 매 과제들은 Top-1 Accuracy 의 일정 % 이상을 달성하도록 목표를 두어 도전적인 자세로 임할 수 있도록 설계되어 있다. 지금까지 수행한 과제는 총 3 가지이다.

**첫 번째 과제**는 CIFAR100<sup>2</sup> Dataset 을 import 하지 않은 채 직접 구현하는 과제였다. 이후 ResNet<sup>3</sup>을 바탕으로 Hyperparameter Tuning 을 통해 모델의 성능을 향상시키는 것이 목표였다. 그림 3 에서 해당 과제의 내용을 확인할 수 있다.

**두 번째 과제**는 Hyperparameter Tuning 을 하지 않고 오직 모델 구조만을 수정하여 CIFAR100 Dataset 에 대한 모델의 성능을 향상시키고, 학습된 모델을 Teacher Model 으로 하여 Knowledge Distillation<sup>4</sup>을 수행하는 것이었다.

**세 번째 과제**는 DDP 의 개념을 이해하고 직접 코드에 적용시켜 여러 GPU 를 병렬적으로 사용하여 학습시켜 보는 것이었다. 또한 WandB<sup>5</sup>를 이용해 학습 현황과 Argument 및 Option 들을 쉽게 확인할 수 있도록 WandB 의 사용법을 이해하고 코드에 로깅 기능을 추가하는 실습을 진행하였다.

<sup>2</sup> <https://www.cs.toronto.edu/~kriz/cifar.html>

<sup>3</sup> He et al., 2016, Deep Residual Learning for Image Recognition

<sup>4</sup> Hinton et al., 2014, Distilling the Knowledge in a Neural Network

<sup>5</sup> <https://wandb.ai/>



이러한 과제들을 통해 기존의 코드들이 어떻게 작성되었는지 이해할 수 있었고, Ablation Study 를 통해 모델 아키텍처와 Hyperparameter 각 요인들이 모델의 성능에 어떤 영향을 미치는지 확인할 수 있었다. 이후 남은 연구기간 동안 5 개의 프로젝트를 추가로 진행할 예정이며, 튜티들간의 챌린지도 진행하여 경쟁적인 상황에서 모델의 성능을 얼마정도까지 향상시킬 수 있는지 확인해볼 예정이다.

### 3-2. 산학협력 프로젝트 (결함예측)

산학협력 프로젝트로는 외관상 보이지 않는 내부 결함들을 확인하는 머신러닝 모델을 개발하는 결함예측 연구를 진행하고 있다. 내부 결함들을 직접 확인하는데 소요되는 비용과 시간의 낭비를 최소화하는 것이 연구의 목적이며, 그림 4 에서 연구계획서를 확인할 수 있다. 이미 연구를 진행하고 있는 인원으로부터 연구 진행 상황을 인계 받았으며, 현재는 데이터 증강을 위해 dicom 파일을 Poisson Blending 처리하는 방법에 대해 연구하고 있다.

### 3-3. 개인 프로젝트 (Continual Learning)

연구를 진행하던 중 문득 '학습에서 제시되는 데이터의 순서도 결과에 영향을 미칠까?'라는 점이 궁금해져 관련된 연구를 진행하고 있다. Continual Learning, 특히 Class Incremental 을 중점으로 기존에 이미 연구된 내용을 학습하고 있으며, 동시에 모델에 일부 Class 만 학습시켰을 때의 결과를 실험하고 있다. 최종적인 목표는 학습 데이터의 순서와 관련된 학습 방법론 또는 모델을 제시하여 새로운 State-of-the-Art 를 달성하는 것이다. 연구 진행 현황은 해당 Github Repository<sup>6</sup>에서 확인할 수 있다.

## 4. 결론

기존의 논문들을 정독하고 정리한 후 생각을 정리하여 발표하고, 세 개의 프로젝트와 실습들을 통해 이를 직접 구현해 봄으로써 '기존의 지식을 이해하고 새로운 연구를 할 수 있는 연구자로서의 준비를 한다'는 연구 목적에 맞게, 연구자로서 갖추어야 할 지식과 능력들을 기르는데 노력하고 있다. 또한 연구 내용을 모두 GitHub 에 저장하여 연구 내용과 새롭게 알게 된 지식들을 보존하고 정리할 수 있도록 하였으며, 필요할 경우 언제든지 내용을 공유하고 더 나아가 협업할 수 있도록 준비하였다. 이후 개인 프로젝트를 중심으로 새로운 발견을 할 수 있는 연구자가 될 수 있도록 끊임없이 노력할 예정이다.

<sup>6</sup> <https://github.com/Chihiro0623/ContinualLearning>

July 5, 2023

AJOU UNIVERSITY

Problem 1
<p>1. Due date: 7.17. (Mon) 10 A.M.</p> <p>2. Goal: On <b>CIFAR100</b> dataset, achieves top-1 accuracy &gt; 80% within 3 hour.</p> <p>3. Rules:</p> <p>a) Train your network from scratch using train split and evaluate the network on test split, do not finetune or use the weight pre-trained from other datasets.</p> <p>b) Write your code yourself, which includes network, train &amp; eval loop, metric, <i>dataset</i> (do not just import <code>torchvision.datasets.CIFAR100</code>), etc. Referring to other codes is okay but just copy &amp; paste from <code>GitHub</code> is not allowed.</p> <p>c) Use <b>pytorch</b> library. Because our lab members including your mentor mainly work on <b>pytorch</b> library, you will get more practical feedback if you use the <b>pytorch</b> library.</p> <p>d) Summarize the experiment result and write a report on a single paper (A4-sized, pdf). The report must include (1) the training hyper-parameters e.g. epoch, network type, flops, parameters, and image size, (2) the experiment results such as the best top-1 &amp; 5 accuracies, training time, and epoch vs eval-top1-acc graph, (3) your novel argument for fast network convergences. e.g. <i>We argue that the Adam optimizer is the key factor for fast network convergence. In the experiment, the Adam optimizer improves 2.3% accuracy improvement.</i> Within a single paper, any contents other than mentioned things are okay.</p> <p>e) Prepare the presentation (&lt;3 min) using your single-paper report. Please show us the figures and tables, not texts.</p>

그림 3. 첫 주에 진행된 멘토멘티 프로젝트 1의 일부.

## [연구계획서]

## 1. 연구목적 (필요성) :

- 외관 상 보이지 않는 내부 결함의 경우, 결함의 확인에 어려움에 어려움이 있음
  - 일반적인 방법으로 결함의 확인은 비용과 시간의 낭비가 클 수 밖에 없음
- 내부 결함의 예측을 위한 효율적인 방법이 필요
  - 내부 결함의 경우 그 경우가 적기 때문에 결함을 예측 할 수 있는 방법이 있다면, 결함을 확인하는 시간과 비용을 줄일 수 있음.

## 2. 연구내용 및 방법 :

방사선 데이터를 통한 효율적인 결함 예측 머신러닝 모델 개발. 학생들은 모델 개발을 위한 머신러닝, 딥러닝, 영상인식과 관련된 기초지식 공부와 관련연구 조사 등을 병행하여 연구를 진행함.

## 1. 데이터셋 구축

## ○ 데이터셋 분류

- 데이터를 결함 유무로 분류하여 정상, 결함 데이터를 분류하는 모델을 학습 가능하다.

## 2. 모델 탐색 및 선정

## ○ 모델 학습

- ResNet, DenseNet 등 기존의 검증된 모델들을 활용하여 방사선 데이터셋에 대한 학습을 진행

## ○ 모델 검증 및 선정

- 방사선 데이터셋으로 학습된 다양한 모델들에 대한 성능 검증을 진행하여, 최적의 모델 선정
- 검증 지표는 accuracy를 사용한다.




그림 4. 결함예측 산학협력 프로젝트 연구계획서의 일부.